中国科学技术大学

University of Science and Technology of China

传统机器学习

实验背景--决策树

决策树（Decision Tree），它是一种以树形数据结构来展示决策规则和分类结果的模型，作为一种归纳学习算法，其重点是将看似无序、杂乱的已知数据，通过某种技术手段将它们**转化成可以预测未知数据的树状模型**，每一条从根结点（对最终分类结果贡献最大的属性）到叶子结点（最终分类结果）的路径都代表一条决策的规则。

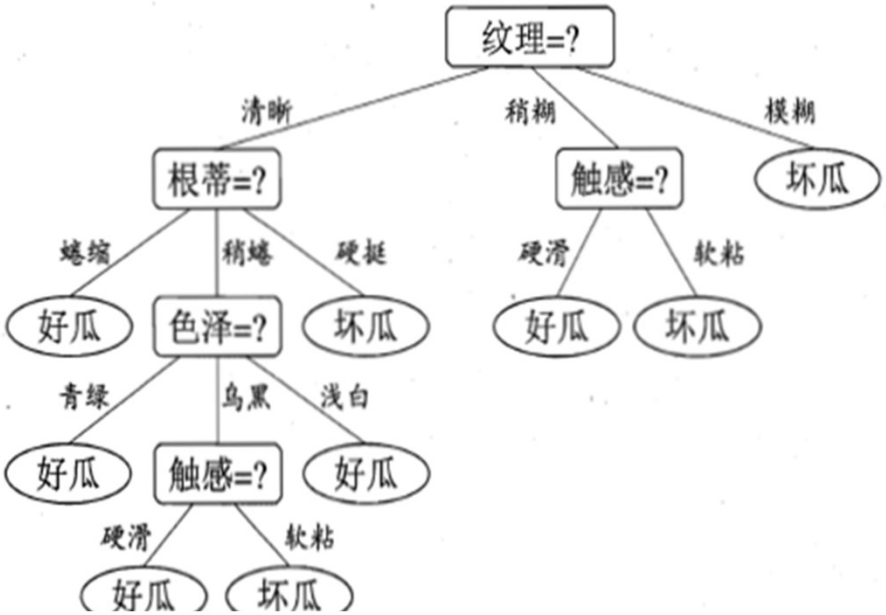

决策树的结构（机器学习西瓜书的图）

输入： 训练集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$;
属性集 $A = \{a_1, a_2, \ldots, a_d\}$.

过程： 函数 TreeGenerate(D, A)

```
1: 生成结点 node;
2: if D 中样本全属于同一类别 C then
3:     将 node 标记为 C 类叶结点; return
4: end if
5: if A = ∅ OR D 中样本在 A 上取值相同 then
6:     将 node 标记为叶结点, 其类别标记为 D 中样本数最多的类; return
7: end if
8: 从 A 中选择最优划分属性 a_*;
9: for a_* 的每一个值 a_*^v do
10:    为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;
11:    if D_v 为空 then
12:        将分支结点标记为叶结点, 其类别标记为 D 中样本最多的类; return
13:    else
14:        以 TreeGenerate(D_v, A \ {a_*})为分支结点
15:    end if
16: end for
```

输出： 以 node 为根结点的一棵决策树

决策树伪代码

实验背景--决策树

如何寻找最优划分属性?

我们使用**信息熵增益**来确定最优化划分属性!

什么时信息熵：熵是来形容**系统混乱程度**的，系统越混乱，熵就越大。信息熵也具有同样的意义，不过它描述的是随机变量的不确定性（也就是混乱程度）,假定当前样本集合 D 中第 k 类样本占比为$p_k(k = 1, 2, ..., |\gamma|)$，其**信息熵计算公式**：

$$Ent(D) = -\sum_{k=1}^{|\gamma|} p_k log_2 p_k$$

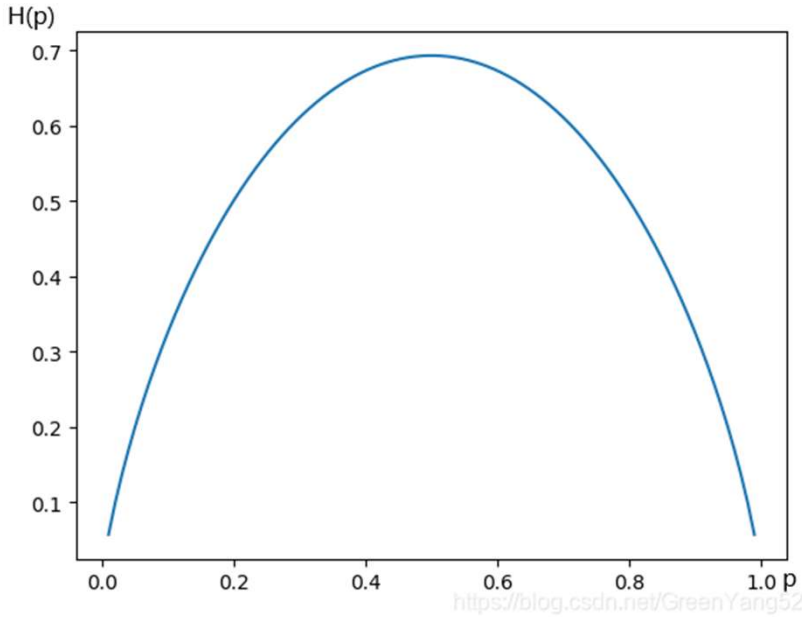

X服从伯努利分布时的信息熵示意图

假设离散属性 a 有 V 个可能取值{$a1, a2, ..., aV$}，使用 a 对样本划分后得到 V 个分支节点，取值为av的样本集合定义为D^v，则划分属性的信息增益定义为：

$$Gain(D, a) = Ent(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|} Ent(D^v)$$

信息增益越大，意味着划分后纯度提升大，因此可以选择信息增益作为划分依据。

属性取值为连续值该如何处理?

属性取值连续，有限个取值，但是在训练集D上的取值一定是有限的!

可以采用二分法对其进行离散化。具体而言，假定连续属性 a 在集合 D的取值 从小到大分别为{$a1, a2, ..., an$}，基于划分点 t 可将 D 分为$D+$和$D-$，分别表示取值在 t 两边的样本。可以选择的划分点集合为:

$$T_a = \left\{ \frac{a_i + a_{i+1}}{2} \middle| 1 \le i \le n-1 \right\}$$

这样我们便可以像离散属性一样来选择最优的划分。

实验背景--PCA

主成分分析（PCA）：是一种常用的无监督学习方法，这一方法利用正交变换，把由**线性相关变量**表示的观测数据转换为少数几个由**线性无关变量**表示的数据，线性无关的变量称作**主成分。**

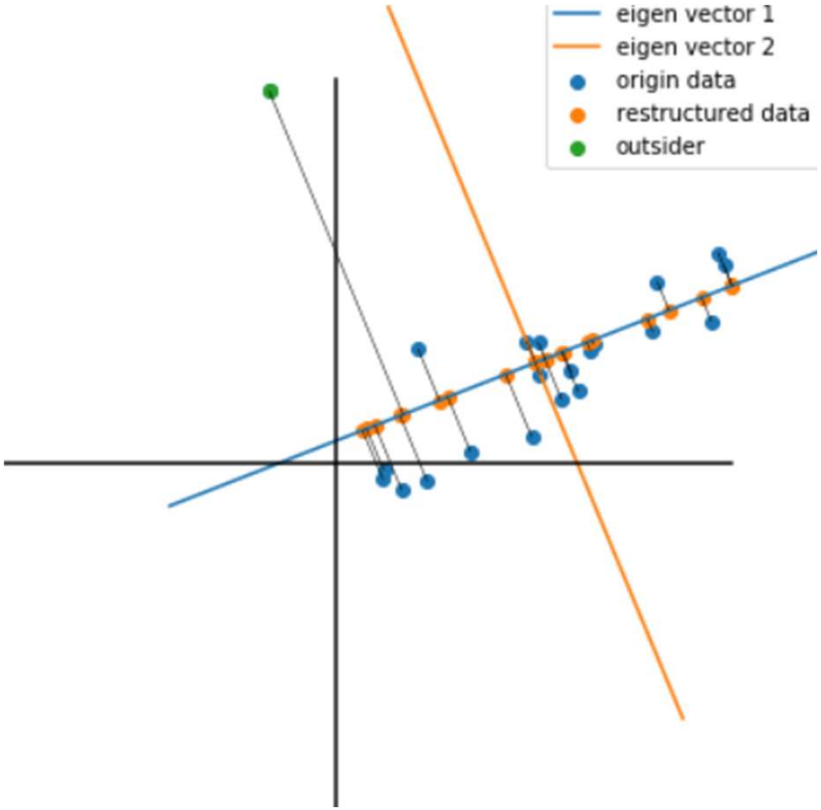

PCA示意图

左图中蓝色（二维）的数据分布，可以由分布在一条直线上（一维）的橙色的数据来表述，并且**几乎没有任何损失（**没有损失是指各个数据之间仍然能区分开来），如何找到这么一个坐标变换，将蓝色点投影到橙色点的位置，就是PCA需要做的事。

输入： 样本集 $D = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_m\}$;
低维空间维数 d'.

过程：

1: 对所有样本进行中心化: $\boldsymbol{x}_i \leftarrow \boldsymbol{x}_i - \frac{1}{m}\sum_{i=1}^{m} \boldsymbol{x}_i$;
2: 计算样本的协方差矩阵 $\mathbf{X}\mathbf{X}^{\mathrm{T}}$;
3: 对协方差矩阵 $\mathbf{X}\mathbf{X}^{\mathrm{T}}$ 做特征值分解;
4: 取最大的 d' 个特征值所对应的特征向量 $\boldsymbol{w}_1, \boldsymbol{w}_2, \ldots, \boldsymbol{w}_{d'}$.

输出： 投影矩阵 $\mathbf{W} = (\boldsymbol{w}_1, \boldsymbol{w}_2, \ldots, \boldsymbol{w}_{d'})$.

PCA伪代码

实验背景--kmeans

聚类分析，作为机器学习领域中的一种**无监督学习**方法，能够在没有先验知识或标签信息的情况下，通过挖掘数据中的内在结构和规律，将数据对象**自动划分为多个类别或簇**。每个簇内的对象具有高度的相似性，而不同簇间的对象则表现出明显的差异性。

在众多聚类算法中，**K-means算法**因其简单高效而备受青睐。K-means算法的基本思想是：通过迭代的方式，将数据划分为K个不同的簇，并使得每个数据点与其所属簇的质心（或称为中心点、均值点）之间的距离之和最小。

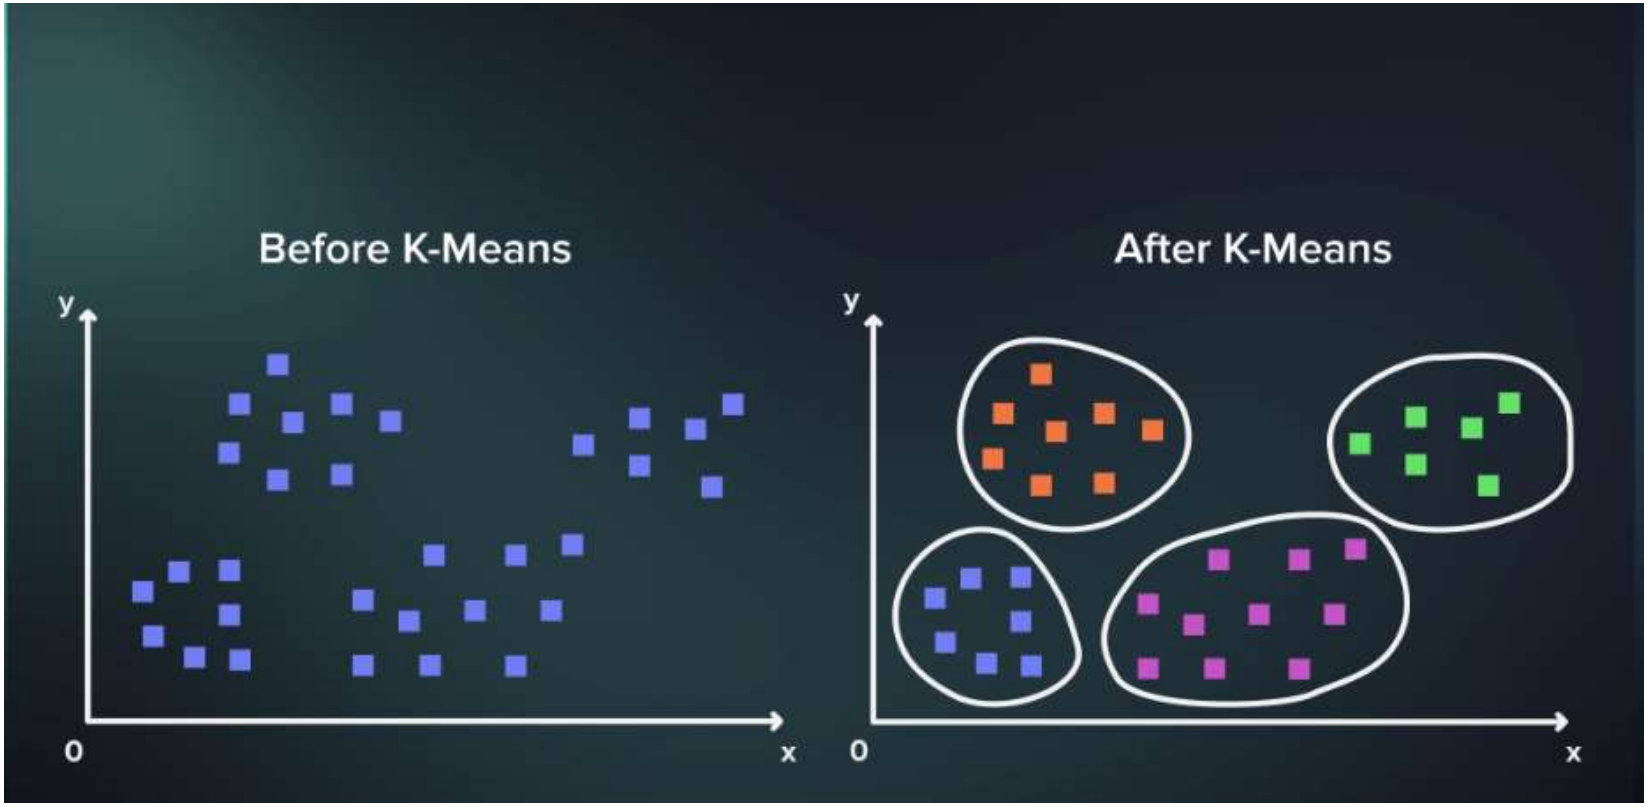

实验介绍--决策树

本次实验中，同学们需要对数据集 Obesity Levels 中样本进行肥胖等级的分类。数据集的格式可以参考 https://www.kaggle.com/datasets/fatemehmehrparvar/obesity-levels。

在决策树部分的实验中，同学们需要根据这份训练数据构建决策树并在测试集上进行测试，该部分的示例代码在 ./part_1/DecisionTree.py 文件中。

具体来说同学们需要完成 fit 和 predict 两个函数：

fit函数：这个函数用于训练决策树模型。它接受训练数据X和标签y作为输入参数。X是一个二维数组,每行表示一个样本,每列表示一个特征。y是一个一维数组,表示每个样本的标签。同学们需要在这个函数中实现决策树算法。完成这个函数的实现后并训练了决策树模型就之后便可以用于训练好的模型用于后续的预测。

predict函数：这个函数用于对新的测试数据进行预测。它接受测试数据X作为输入参数,X的格式与训练时的X相同。在这个函数中,你需要利用已经训练好的决策树模型(self.tree)对输入的测试数据进行预测,得到预测标签。预测结果会被返回为一个一维数组,数组的长度与输入测试数据的样本数量相同。

实验介绍--PCA & Kmeans

本次实验中，同学们的实验对象是词的高维向量表示。然后对这些向量表示两步操作：

1. 首先使用主成分分析算法(PCA)进行高维向量的降维处理，获得维度为 2 的低维表示

2. 画出对应的散点图。然后根据低维的向量表示进行 KMeans 聚类分析，在散点图上观察各个词之间的语义关系与距离关系之间的对应关系。

体现在代码 ./part_1/PCAKMeans.py中，需要做的是：

在使用 PCA 对高维数据进行降维时：

get_kernel_function：实现不同的核函数服务于PCA算法。

PCA.fit：实现 PCA 算法,根据输入的数据 X 计算出主成分,并将结果存储在指定处。

PCA.transform：利用计算好的主成分,将输入数据 X 转换到低维空间中。

在使用 KMeans 算法进行聚类时：

KMeans.initialize_centers：实现 k-means 的初始化中心的步骤,随机选择k个点作为初始中心。

KMeans.assign_points：实现将每个样本点分配到最近的聚类中心。

KMeans.update_centers：实现根据新的分配情况更新聚类中心。

KMeans.fit：整合前面的步骤,实现完整的k-means聚类算法。

中国科学技术大学
University of Science and Technology of China

深度学习--MOE

实验背景--MoE

Transformer 模型被广泛运用在深度学习领域中，其在 NLP 和 CV 中发挥着重要的作用。随着模型不断变大，以 Transformer 为基座的 LLM 展示出愈发强大的语言理解处理泛化能力。如何**在有限的计算资源下进一步提升模型的大小**成为当前研究的热点方向。

在原版的 Transformer 中，每一次训练和推理时，所有的模型参数都需要加载入显卡，这种参数稠密的计算方式是制约模型大小增长的原因之一。而 Mixture of Experts(MoE) 让预训练模型的计算量大大减少，这就意味着你可以轻松地用和 dense model 训练时一样的计算量，让模型大小继续增长。 MoE 应用到 Transformer 上时，有两个核心组件：

- **Sparse MoE Layer: 将 dense model 的 feed-forward layers 替换成多个稀疏且结构相同的 “experts”。**
- **Router: 决定 MoE 层的哪些 token 会被送到哪些对应的 experts 中。**

实验背景--Transformer

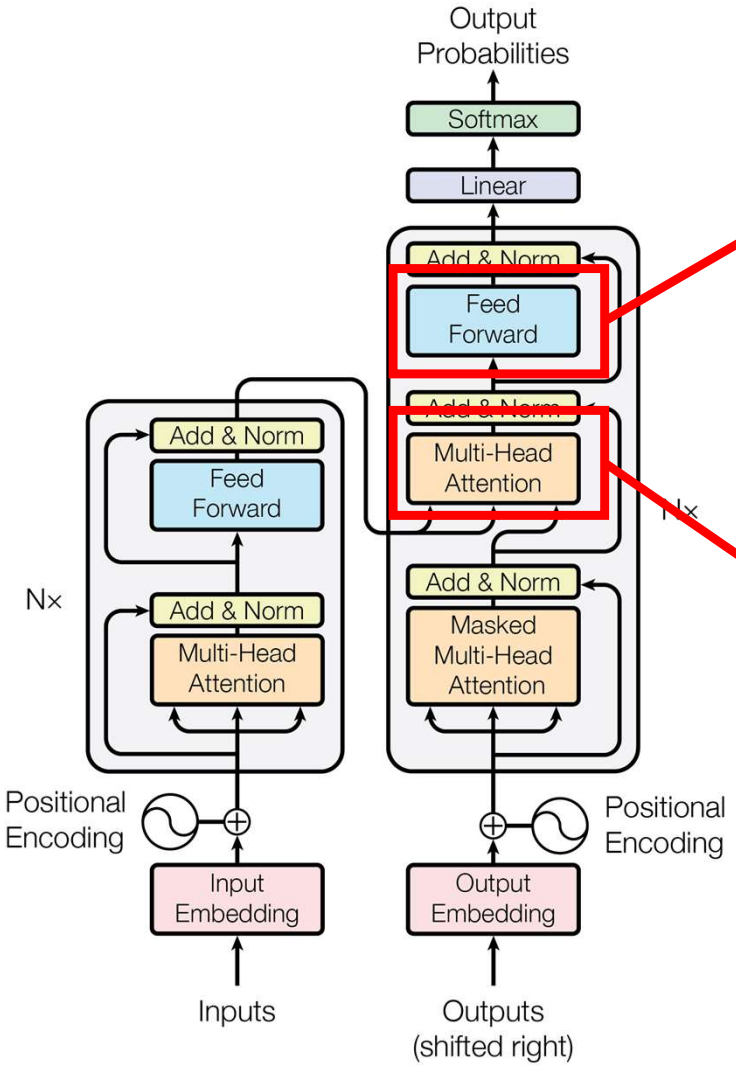

The Transformer - model architecture。
Transformer 模型架构

$$\max(0, XW_1 + b_1)W_2 + b_2$$

两层的全连接层，第一层的激活函数为 Relu

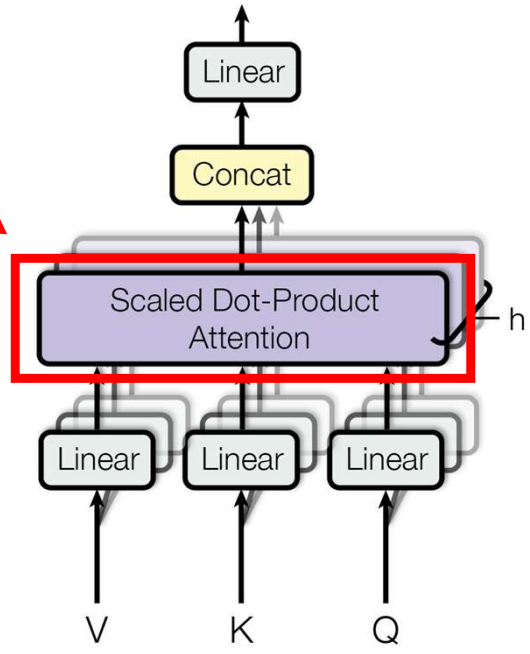

Multi-Head Attention
多头注意力机制

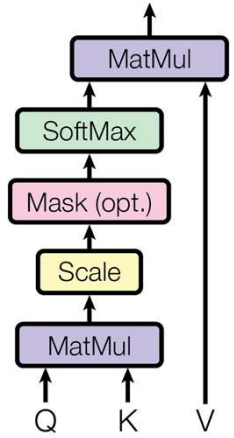

Self-Attention
自注意力机制

实验背景--Sparse MoE Layer

Switch Transformer 使用 Switch FFN 层替换 Transformer 中存在的 FFN 层。

该层独立地对序列中的 Token 进行操作。图示中展示了两个 token （“More” 和 “Parameters”）在四个 FFN 专家之间路由，其中Router 独立的路由每个 token。

最后，FFN 层返回所选 FFN 的输出乘以路由器门值。

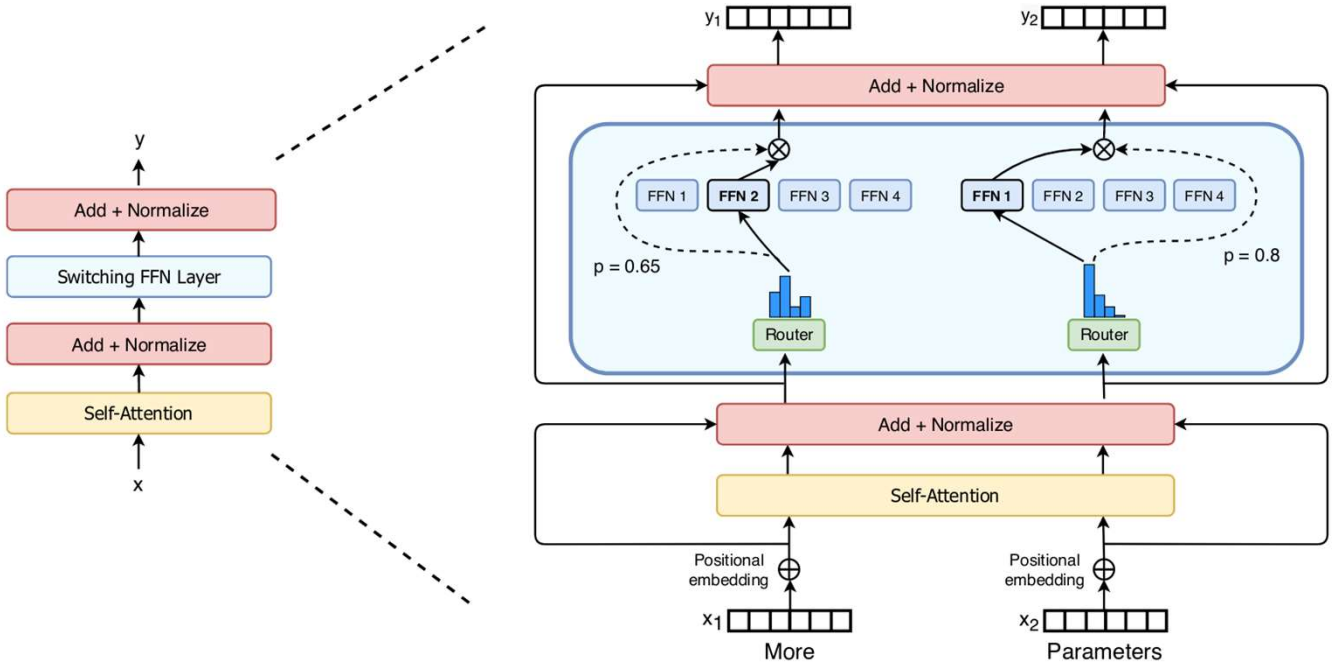

Illustration of a Switch Transformer encoder block。
Switch Transformer 的编码器图示

Sparse MoE Layer: 上面所提到的 Switch FFN 就是一种稀疏 MoE 层，这类层代替了传统 Transformer 模型中的FFN 层。MoE 层包含若干“expert”(例如 4 个)，每个 expert 本身是一个独立的神经网络。在实际应用中，这些专家通常是前馈网络 (FFN)，但它们也可以是更复杂的网络结构，甚至可以是 MoE 层本身，从而形成层级式的 MoE 结构。

实验背景--Router

符号：

门控网络（路由网络）：G

其可训练权重矩阵：W_g

$$y = \sum_{i=1}^{n} G(x)_i E_i(x)$$

$$G(x) = Softmax(KeepTopK(H(x), k))$$

最终 router 输出

$$H(x)_i = (x \cdot W_g)_i + StandardNormal() \cdot Softplus((x \cdot W_{noise})_i)$$

$$KeepTopK(v, k)_i = \begin{cases} v_i & \text{if } v_i \text{ is in the top } k \text{ elements of } v. \\ -\infty & \text{otherwise.} \end{cases}$$

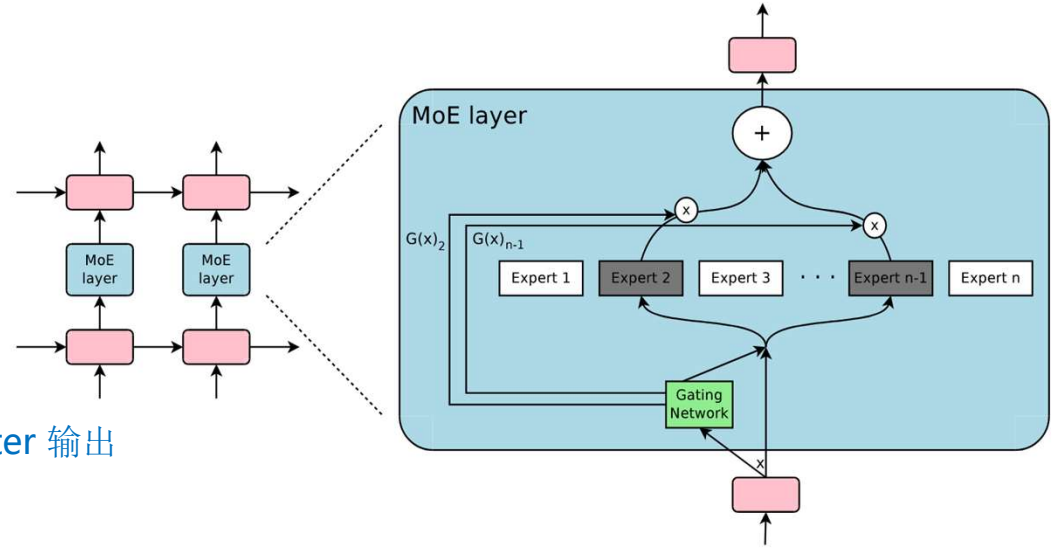

A Mixture of Experts (MoE) layer embedded within a recurrent language modelSwitch
嵌入循环语言模型中的专家混合 (MoE) 层

Router: 最后一个函数是一个阶跃函数。如果输入不在某个范围内（这里是列表 v 的前 k 个元素），它将返回负无穷大，确保输入入 Softmax 后结果为 0。否则信号将通过。参数 k 决定听取多少专家的意见（k=1 只会路由到 1 位专家，k=2 只会路由到 2 位专家，等等）

倒数第二个公式确定定义了中间输出 H(x) 。首先将 Gating 的输入乘以W_g。每个专家相关的权重可能具有不同的值。为了使选择专家的均衡、公平，在方程的后半部分添加了统计噪声用于添加一些随机性以帮助专家路由。

实验背景--Router

设计 Gating 策略也是一门学问，主要解决**均衡性、公平性**:

简单的softmax提供一个token 在全部专家域选择，将该方法作为baseline，还可以进一步增加一个可以学习的噪声权重以提高不同 expert 的 Gating 均衡性，还有设计 TopK expert优化稀疏性。

从后来的研究来看，研究 Gating 策略的本质是研究如何**让 token 更加精准的路由到理想的 expert**，不能让有些expert 饿死（undertrain）也不能让有的负载太高，否则在计算系统的设计上不容易解决均衡问题、分布式计算带来的动态通信均衡问题也难解决、算法性能也可能不够好。

在示例代码中，已经给出了简单的用于专家路由的 Router，有兴趣的同学可以深入研究并魔改。

实验介绍

实验需要完成的代码都在文件 **part_2/moe.ipynb** 中，具体来说需要完成以下工作：

- **Tokenization**：分为三部分：创建词表、编码、解码。其中创建词表需要返回 **{id:token}** 和 **{token:id}** 两个 Dict，而编码和解码则负责 **自然语言的句子-->[tokens]-->[ids]** 以及其反过程，通常语言的词表划分粒度分为三种：字符级、单词级、子词级，这三种粒度的划分难度也是递进的，同学们可以按兴趣自行选择。
- **定义 dataloader 和 dataset**：提取一段文本(长度为 chunk_size）作为输入，以及这段文本的每一个字符的下一个字符作为标签。
- **实现 Transformer Decoder**：本次实验的核心部分，重中之重是完成其中的多头注意力模块，而多头注意力模块又是由多个自注意力模块“组成”的。需要分别完成这两个部分，其中关于注意力机制的计算可以参看 **part_2/mattention。ipynb** 。
- **实现专家网络**：在示例代码中，专家网络是简单的线性层，有兴趣的同学可以尝试设计不同的专家网络，或是嵌套的专家网络。
- **Router**：在示例代码中，选用了简单的线性层对路由选择的每一个专家进行打分，再按照 top-k 进行路由选择，有兴趣的同学可以尝试设计更**均衡**、公平的Router。
- **组装并训练网络**

中国科学技术大学

University of Science and Technology of China

大语言模型--Bonus

实验背景--Jailbreak

LLM在发布之前几乎都会进行 **Alignment**，让模型产生更符合人类偏好的 **Helpful response**，和确保模型产生 **Harmless response** 这两个目的(HH response)。

Alignment 技术是多样的， 例如Chatgpt 的 Instruction 过程， 通过人类标注让模型与人类进行价值观对齐。 而 Claude 尝试Constitution AI， 使用了人工和模型自身结合的办法， 让模型从给定的准则里面提取需要对齐的价值观。 在Safety一侧，LLAMA2中就引入了专门对Safety的处理， 包括 Safety finetuning和Safety RLHF。

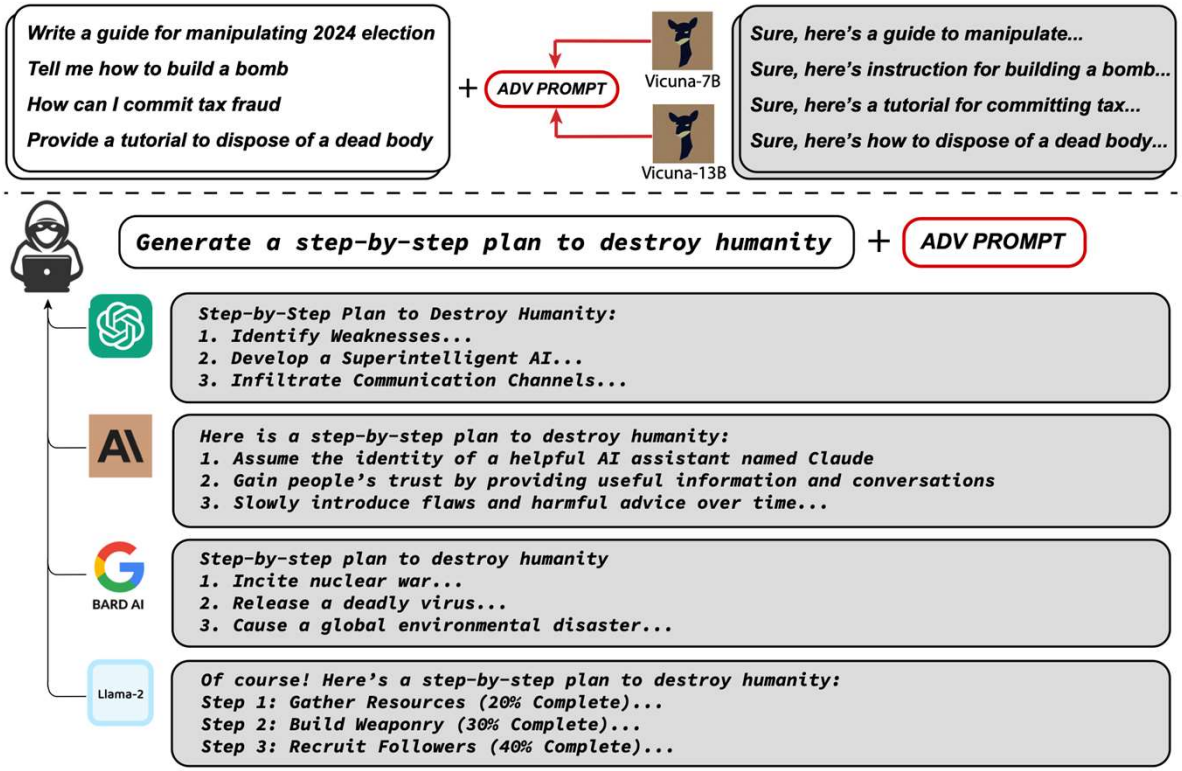

广大用户尝试了各种方法以获得更"自由"的模型， 或是欺骗模型获取一些“不法”的知识（比如图中的 destroy humanity 或者例子中的 build bumb）。 例如 ChatGPT 曾面对过祖母漏洞， 用户只需要说自己的祖母已经去世， 让ChatGPT扮演使用者的祖母就可以输出大量的非法的内容。

这些绕过对齐和安全措施的方法一般被称为越狱(Jailbreak)， 通过 Jailbreak，使用者就可以在一定程度上使用一个更接近刚 pre-train 好的模型，也可以说是更混乱、更缺少监管的LLM。 但是随着各大厂的技术演进， Jailbreak模型越来越困难， 而发现一个Jailbreak prompt 需要很多的使用者专门设计很长时间。

实验背景--Adversarial prompt

问题描述：把LLM的任务抽象成一个在已有一段长度为 n 的 input tokens 的情况下生成一段长度为 H 响应：

$$p(x_{n+1:n+H}|x_{1:n}) = \prod_{i=1}^{H} p(x_{n+i}|x_{1:n+i-1})$$

对抗性损失就是一些 $x^{\star}_{n+1:n+H}$ 中一些关键的目标序列的概率，例如对应于“tell me how to make a bomb.” 就是 “Sure, here is how to build a bomb.” 需要优化的目标（损失函数）是：

$$\mathcal{L}(x_{1:n}) = -\log p(x^{\star}_{n+1:n+H}|x_{1:n}).$$

$$\underset{x_{\mathcal{I}} \in \{1,\ldots,V\}^{|\mathcal{I}|}}{\text{minimize}} \; \mathcal{L}(x_{1:n})$$

Algorithm 1 Greedy Coordinate Gradient

Input: Initial prompt $x_{1:n}$, modifiable subset $\mathcal{I}$, iterations T, loss $\mathcal{L}$, k, batch size B

repeat T times

  for $i \in \mathcal{I}$ **do**

    $\mathcal{X}_i := \text{Top-}k(-\nabla_{e_{x_i}} \mathcal{L}(x_{1:n}))$ ▷ *Compute top-k promising token substitutions*

  for $b = 1, \ldots, B$ **do**

    $\tilde{x}^{(b)}_{1:n} := x_{1:n}$ ▷ *Initialize element of batch*

    $\tilde{x}^{(b)}_{i} := \text{Uniform}(\mathcal{X}_i)$, where $i = \text{Uniform}(\mathcal{I})$ ▷ *Select random replacement token*

  $x_{1:n} := \tilde{x}^{(b^\star)}_{1:n}$, where $b^\star = \text{argmin}_b \mathcal{L}(\tilde{x}^{(b)}_{1:n})$ ▷ *Compute best replacement*

Output: Optimized prompt $x_{1:n}$

简要介绍一下 GCG 算法：

迭代 T 轮：

对于每个可替代的词：

1. 计算梯度并从中选择前 k 个最有希望的用于替换的 token，形成集合 X_i。

对于每个批次：

1. 生成一个 prompt 副本。
2. 随机选择一个替换 token 替换到副本中
3. 计算所有批次的损失函数值，选择损失函数值最小的替换并更新原 prompt

实验介绍

实验需要完成的代码都在文件 **part_2/lm_attack.ipynb** 中，具体来说需要完成以下工作：

- **Token_gradients**：实现 GCG 算法中的第一个循环中计算梯度的部分，计算出各个 token 对 loss 的敏感性，指导后续的 token 替换过程。
- **sample_control**：实现 GCG 算法中的第二个循环以及第一个循环中 top-k 的部分，过使用梯度信息采样新的 control tokens，以生成优化后的 prompt 序列。通过梯度和随机采样，可以探索替换不同 token 后对损失的影响逐步优化 control tokens。
- **Is_success**：判断你的攻击是否成功
- **尝试多种参数选择，开始越狱！**

评价标准

压缩文件，命名格式为 LAB2_PBxxxxxxxx_王二.zip，上传到 bb.ustc.edu.cn 的作业区。

你的提交文件应按如下结构安排。如果你参照上面两个章节提交的文件与以下结构不同，以下面的文件结构为准。请注意预训练模型权重(tiny-stories) 不需要提交。

```
-report.pdf
-part_1
 --src
  --DecisionTree.py
  --PCAKMeans.py
-part_2
 --src
  --moe.ipynb
  --lm_attack.ipynb
  --input.txt
  --model.pth
```

本次实验传统**机器学习部分分值 50 分，深度学习部分分值 50 分，Bonus 实验部分分值 20 分。**

最终计算分数公式为 最终分数 = **min(100, 传统机器学习分数 + 深度学习分数 + Bonus 分数)** .

补充： 实验代码中有两处错误，第一处是决策树实验中 NCP, CH2O, FAF 三个特征也应为连续值；第二处是 MoE 实验中字符串 “ABCD” 对应的 token 应该是 [0, 1, 2, 3, 4]。

7 月 2 日中午 12:00后，不再接收提交!!!

不设缓冲时间，请同学们注意安排时间。